




Contribuíram:

35



Figura 3.1.

Madeira de pinho com um nó e limiarização resultante.



As técnicas de segmentação por crescimento de regiões são uma solução geral para problemas deste tipo: nesta família de técnicas nós partimos do princípio de que partes da imagem “parecidas” devem pertencer ao mesmo “objeto” na imagem e unimos estas em uma única região. Este processo inicia considerando cada pixel como sendo uma região e é repetido iterativamente, unindo-se regiões na imagem até que se atinja um ponto de parada, que geralmente é baseado em algum critério de dessemelhança entre as regiões.

Tons de Cinza

Os dois métodos de segmentação por crescimento de regiões mais importantes para imagens em tons de cinza são a **Segmentação por Watershed**, - o *Método do Divisor de Águas* - e o *Algoritmo do Funcional de Mumford e Shah*.

Destes dois, o watershed é o mais rápido e também o mais sensível a variações nas imagens e por isso, o menos confiável. Existem muitas extensões e variações ao método. A versão que veremos neste capítulo, desenvolvida na Universidade de Kaiserslautern por Gangolf Mittelhäusser [2.4] é uma extensão bastante poderosa. A idéia básica do watershed é dada pela imagem da tradução em português do nome: um divisor de águas é uma cadeia de montanhas, que divide a água da chuva em regiões para onde ela corre. Watershed utiliza os módulos dos gradientes, as variações locais de intensidade luminosa na imagem, como uma “topografia” montanhosa que separa regiões. Fundimos regiões aumentando a altura da água que “chove” na imagem. A grande



vantagem do watershed é a sua rapidez de processamento, permitindo que seja utilizado em aplicações interativas, mesmo quando as imagens a serem processadas são grandes e complexas.

O Algoritmo de Mumford e Shah [2.1] é um método que usa a idéia de que as regiões são grupos de píxeis com uma “borracha” ao redor. As regiões crescem enquanto pudermos esticar a borracha. Quanto maiores as variações entre os píxeis dentro de uma região, tanto menor a elasticidade da borracha. Do ponto de vista matemático, o algoritmo de Mumford&Shah é genial pela sua simplicidade. De todos os algoritmos de crescimento de regiões é de longe o que produz os melhores resultados. Seu maior problema é o tempo de processamento, que é bastante longo. O Algoritmo de Mumford e Shah é indicado para situações onde uma segmentação confiável e estável com o Watershed não é possível para o tipo de dados que se trabalha e onde é possível esperar pelos resultados, eventualmente através de processamento em lote.

Imagens a Cores

Para as imagens a cores nós podemos com certeza desenvolver generalizações desses dois algoritmos anteriores, de forma a que trabalhem em um espaço de valor de pixel tridimensional (R,G,B)(x,y) ao invés do espaço de valor unidimensional tons de cinza g(x,y). A diferença básica é a de que teríamos de trabalhar neste espaço tridimensional para quantificarmos a distância entre um valor de pixel e outro, para podermos dizer se devem pertencer a mesma região ou não. Um enfoque bem simples para isso seria a própria distância euclidiana no espaço RGB, dada por $\sqrt{dR^2 + dG^2 + dB^2}$, entre os valores RGB de dois píxeis.

O problema que surge quando realizamos generalizações deste tipo para métodos que já são computacionalmente intensos, como os dois citados anteriormente, é que a complexidade destes cresce a ponto deles se tornarem impraticáveis. Um outro enfoque, bastante mais promissor, é o de se aproveitar o fato de que uma imagem colorida possui muito mais informação do que uma imagem em tons de cinza e de se utilizar estas informações de forma mais objetiva, com métodos mais simples. Para imagens em tons de cinza, precisamos de métodos sensíveis e complexos, como o Watershed e o Mumford&Shah, porque as imagens



são pobres em informação. As imagens a cores permitem que se usem métodos mais simples para isto.

O terceiro método de segmentação de imagens por crescimento de regiões apresentado neste capítulo é um método desenvolvido pela Universidade de Koblenz, Alemanha, em conjunto com a empresa Daimler-Benz, especialmente para a utilização em tempo real no sistema de reconhecimento de placas de trânsito de uma futura versão do piloto automático da Classe S da linha de carros Mercedes. Este método, chamado de *CSC - Color Structure Code*, utiliza um algoritmo de crescimento de regiões hierárquico que divide a imagem em células recursivas e usa informações estatísticas simples para calcular se vai ou não unir duas regiões: probabilidades dependentes. O algoritmo é baseado em um modelo do mundo e real e tem uma tabela, que dá a probabilidade de uma célula de uma cor pertencer a uma região de outra cor média, em função das cores de sua vizinhança. Isto permite ao algoritmo trabalhar em tempo real e obter resultados excelentes.

Técnicas de agrupamento no domínio espacial (crescimento de regiões)

Conecção simples

Segundo este enfoque, os pixels que possuem propriedades similares são simplesmente agrupados em segmentos. A similaridade pode ser definida por valor escalar ou vetorial dos pixels conforme descrito nas subseções a seguir. Esta é sem dúvida a forma mais simples de se segmentar uma imagem no domínio espacial.

Pixels com valor escalar

Os pixels podem ser agrupados por proximidade de valor escalar ou desvio padrão. Com valor escalar, é feita uma normalização de todos os pixels e agrupa-se pixels com valores próximos, formando assim uma região de interesse. Na figura abaixo, os pixels com valores não distantes de 5 são agrupados em 3 regiões.

Figura 3.2.

Formação de regiões por proximidade de valores

50	51	50	102
51	49	50	102
240	240	102	102
241	240	103	103


50	51	50	102
51	49	50	102
240	240	102	102
241	240	103	103

Outra técnica que pode ser empregada é utilizada é a separação de regiões pelo desvio padrão. Os pixels que possuírem valores dentro de um determinado desvio padrão desejado formam o segmento de interesse.



Figura 3.3.

Pixels com valores fora do desvio padrão são descartados



Pixels com valor vetorial (i.e. RGB, IHS, etc.)

Alguns tipos de pixels são expressos em componentes vetoriais. As regiões neste caso podem ser estabelecidas delimitando-se a distância vetorial entre eles. A distância vetorial pode ser obtida da seguinte maneira.

- Sejam os pixels com valor vetorial $x = x_1, x_2, x_3$ e $y = y_1, y_2, y_3$ a distância entre eles pode ser obtida da seguinte maneira:

$$D(x, y) = \|x - y\| \text{ ou}$$


$$D(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2}$$

Fórmula 9:

Depois de calculada a distância separam-se pixels com valores próximos em grupos.

Conecção híbrida

A conexão híbrida é um recurso melhor que a conexão simples para a análise de imagens. A sua vantagem se baseia no fato de que a propriedade atribuída a cada pixel depende de uma matriz $K \times K$ que ocupa a



vizinhança ao redor do pixel que esta sendo analisado. Esta técnica se baseia no fato de que os pixels possuem propriedades semelhantes por que a sua vizinhança possui uma certa similaridade. Uma das técnicas mais empregadas para a demarcação de um segmento é a detecção de bordas. Esta técnica é utilizada para determinar quando dois pixels podem ser conectados por um arco ou não, e formar um segmento de imagem. Assim sendo a qualidade da técnica de segmentação é altamente dependente do tipo de detetor de borda utilizado. Vale a pena ressaltar que uma região só pode ser definida como sendo um segmento, se e somente se ela for uma região completamente fechada por pixels marcados como bordas. As bordas que se apresentam fragmentadas trazem uma certa dificuldade na formação de um segmento e devem ser eliminadas. As técnicas mais comuns de desfragmentação de bordas são apresentadas nos sub itens a seguir.

Conecção por Centróide

Neste método em contraste com a conexão simples, os pixels não são agrupados por similaridade. A segmentação por centróide se baseia no seguinte procedimento. A imagem em questão passa por uma varredura. Cada pixel é comparado com a média de uma região próxima e pré estabelecida, mas que ainda não foi definida como segmento. Se o valor do pixel for próximo a média de uma região, ele será adicionado a esta região e a média da região é atualizada. Se for encontrado mais de uma região próxima, o pixel será acrescentado aquela cuja a média possuir o valor mais próximo. Se duas regiões diferentes forem muito próximas, então elas são fundidas em uma só e o pixel será adicionado a esta nova fusão. Se o valor do pixel não possuir o valor próximo a nenhuma região existente, então uma nova região é criada e o pixel em questão é adicionado a esta região como primeiro membro.

Combinação de conexão simples e centróide

Combina as melhores características das duas técnicas. A conexão simples coloca as bordas de forma bem precisa. O seu problema é que bordas segmentadas fundem regiões. A conexão por centróide, possui a



característica de detectar bordas mesmo na presença de áreas com pequenos gradientes.

Agrupamento espacial


E o uso das duas técnicas, agrupamento por pixel com crescimento de regiões. Em primeiro lugar é calculado o histograma da imagem. O início do segmento é determinado nos pixels de maior valor (picos). Em seguida é aplicada a técnica de crescimento de regiões.

Dividir e agrupar

Esta técnica consiste em considerar a imagem em um único segmento. A seguir a imagem é sucessivamente dividida em quartos caso ela não apresente boa homogeneidade (diferenças entre os níveis de cinza). Após atingir um limite, as regiões similares são agrupadas.

Figura 3.4.

Exemplo de Dividir e Agrupar




Técnicas combinadas Histograma e crescimento de regiões.

Nesta técnica o ponto inicial de interesse localiza-se no pico do histograma. O crescimento da região é feito partir do pico de interesse.

Divisor de águas (Watershed)

O método de segmentação watershed calcula o gradiente para todos os pixels da imagem. Imagine que os valores de gradiente formem uma superfície topográfica com vales e montanhas. As regiões mais baixas



seriam correspondentes as de menor gradiente e as mais altas as de maior gradiente. O crescimento de regiões seria equivalente a uma inundação feita a partir da abertura de um pequeno furo nas regiões mais baixas. Os segmentos seriam formados por regiões que partindo de um mínimo local, formassem uma bacia hidrográfica. Daí o nome divisor de águas. O agrupamento dos pixels é feito por mecanismos de busca de valores próximos a partir de cada mínimo local.

Segmentação combinada entre crescimento de regiões e divisor de águas.

O método de segmentação combinando segmentação de regiões e divisor de águas, conforme Mittelhaeusser [2.4] define **segmento** da seguinte forma:

"Um segmento é um conjunto de pixels formado por uma região homogênea na imagem, cercado por regiões não homogêneas (bordas) ou por outros segmentos com diferentes níveis médios de cinza".


A homogeneidade se refere também aos valores dos pixels contidos dentro do segmento em questão: Se um segmento não possuir bordas e apresentar-se fragmentado, é por que deve haver um ou mais segmentos vizinhos com gradientes de transição muito suaves entre si. Estas transições suaves são dificilmente detectadas por algoritmos de segmentação baseados em gradientes de valores(watershed). Os métodos que utilizam gradiente apresentam também alguns problemas, como o agrupamento de regiões que apresentam o mesmo gradiente mas com homogeneidade diferente. Além disto, estes algoritmos prevêm também, que a borda entre dois segmentos deve se localizar em um ponto que possui um gradiente mínimo entre eles.

A diferença entre o método combinado e o watershed, é que no primeiro os gradientes são classificados em ordem crescente, antes da inundação. Desta forma, obtêm-se um mecanismo de segmentação muito mais rápido do que o watershed, Além disto, ele determina em toda a imagem as regiões com a mesma homogeneidade, através de um algoritmo de fusão de segmentos.



Figura 3.5.

Exemplo de uma imagem de ressonância magnética e resultado da segmentação da mesma com o método combinado desenvolvido por Mittelhaeuser. Observe-se que o cérebro (estrutura central maior) foi dividido em duas grandes regiões, que a olho nu parecem extremamente similares. Isto é um problema desta técnica: existe um gradiente global na imagem (fica mais escura de baixo para cima) em função da técnica de aquisição que o algoritmo não consegue contornar.




A Segmentação de Mumford e Shah

Continuaremos nosso estudo das técnicas no Domínio Espacial estudando a segmentação por crescimento de regiões de Mumford e Shah [2.1]. Como foi frisado antes, do ponto de vista matemático, o algoritmo de Mumford&Shah é genial pela sua simplicidade. De todos os algoritmos de crescimento de regiões é de longe o que produz os melhores resultados. Na Figura 3.6 na página 45 podemos ver um exemplo de segmentação.

Nesta seção utilizaremos exemplos de segmentações gerados por uma implementação de passo exponencial do pacote MegaWave (Ceremade, Grenoble) adaptada por Andreas Divivier da empresa TecMath, Kaiserslautern e outros gerados por uma implementação de passo linear projetada pelo Departamento de matemática da Universidade de Kaiserslautern.

Figura 3.6.

Segmentação dos nós de pinho do exemplo anterior utilizando Mumford&Shah de passo linear.



Na Figura 3.7 na página 46 podemos ver diversas segmentações realizadas sobre uma ressonância magnética de crânio (imagem mais a esquerda, em cima) com implementações de passo exponencial do algoritmo. Os parâmetros $\lambda = 2^X/\text{tamanho-inicial-de-região}$ encontram-se acima de cada imagem.


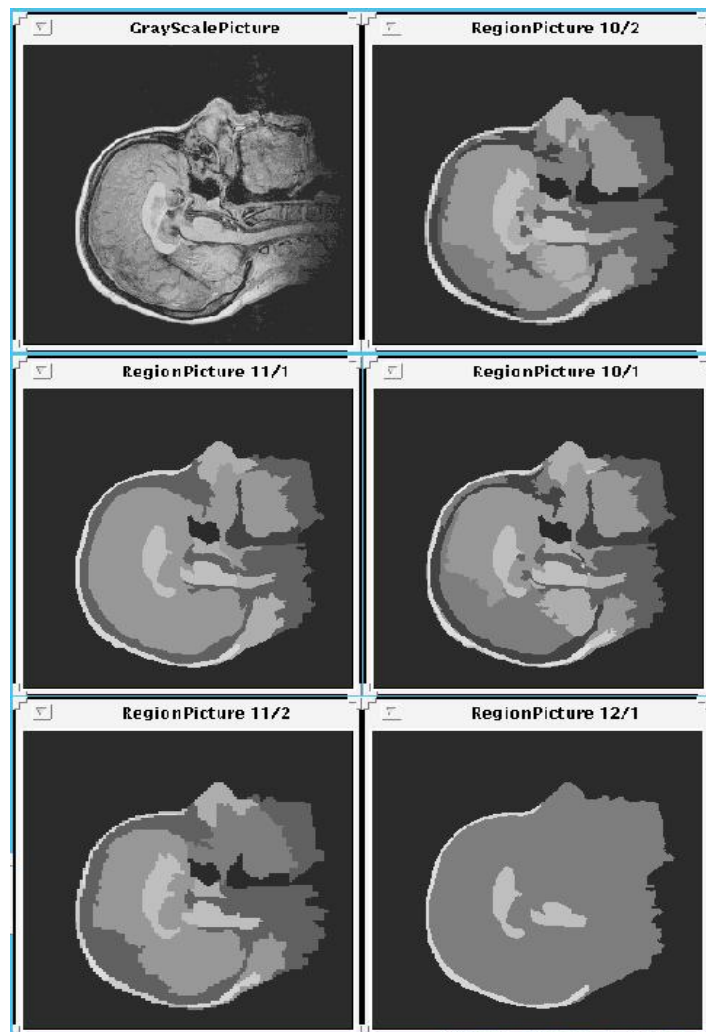


Figura 3.7. Segmentação utilizando diversos parâmetros.

O valor do nível de cinza dos pontos de cada nova região é a média dos pontos agrupados.



Equação Funcional de Mumford-Shah

Este é um método mais preciso para a segmentação, baseado na equação funcional da energia de Mumford-Shah mostrada abaixo:

Fórmula 10:

$$E(u, K) = \iint_{\Omega} \|u - g\|^2 dx dy + \iint_{\Omega / K} \|\nabla u\|^2 dx dy + \lambda * l(K)$$

onde:

$E(\mu, K)$	Energia funcional de Mumford-Shah em função de μ e da fronteira K
$g(x, y)$	Função intensidade de luz (grayvalue) no ponto x, y .
Ω	Domínio da imagem, geralmente um retângulo.
K	Fronteira entre regiões.
Ω_i	Decomposição “piece-wise”, pedaço a pedaço, da imagem. $\Omega = \Omega_1 \cup \Omega_2 \cup \dots \cup \Omega_n \cup K$
$l(K)$	Comprimento total dos arcos das bordas (fronteiras entre as regiões). Reduz-se à medida que regiões vão sendo fundidas.
$\mu(x, y)$	Função diferenciável dentro de cada região Ω_i .
λ	Parâmetro de escala. A cada iteração incrementamos λ . Isso pode ser realizado em passos lineares ou passos exponenciais.

A função $g(x, y)$ é suave (valor de gradiente pequeno) dentro de cada região Ω_i (piece-wise), e é descontínua (valor de gradiente elevado) no cruzamento com as bordas (fronteiras entre regiões).

Para o nosso caso, a função $\mu(x, y)$ será uma função constante, que é diferenciável dentro da região. E esse valor constante será a média dos valores de intensidade $g(x, y)$ de cada ponto da região.

Significado dos Termos da Equação Funcional de Mumford & Shah

Agora vamos interpretar o significado de cada termo da equação funcional da energia de Mumford-Shah:

CAPÍTULO 3. Segmentação por Crescimento de Regiões



Fórmula 11:

Primeiro termo: Mede se $\mu(x,y)$ é uma boa aproximação de $g(x,y)$:

$$\iint_{\Omega} \|u - g\|^2 dx dy$$

Quanto melhor a função $\mu(x,y)$ se aproximar da função $g(x,y)$, menor será a contribuição desse termo para o valor da energia.

Fórmula 12:

Segundo termo: Calcula a variação mínima de $\mu(x,y)$ dentro de cada região sem a borda.

$$\iint_{\Omega \setminus K} \|\nabla u\|^2 dx dy$$

No nosso caso como a função $\mu(x,y)$ será o valor média dos pontos de $g(x,y)$ dentro da região e portanto um valor constante, não existirá variação, assim este termo será sempre zero.

Fórmula 13:

Terceiro termo: Calcula o comprimento das fronteiras multiplicado por um parâmetro de escala λ .

$$\lambda * l(K)$$


Quanto maior o comprimento das fronteiras, maior será a contribuição desse termo para o valor da energia. Esse valor será multiplicado por um parâmetro que funciona como um peso.

Energia Funcional Simplificada de Mumford-Shah

Fórmula 14:

$$E(K) = \iint_{\Omega \setminus K} \|u - g\|^2 dx dy + \lambda * l(K)$$

Assume $\mu(x,y)$ como função constante dentro de cada região, a qual é a média dos valores de $g(x,y)$ nesta região. A função da energia simplificada de Mumford-Shah fica em função apenas de K (fronteiras das regiões).



Crítério de Junção

Dadas duas regiões adjacentes O_i e O_j separadas por uma fronteira comum $\delta(O_i, O_j)$ e o valor de energia $E(\mu, K)$. Uma nova segmentação (μ', K') será obtida, removendo-se a fronteira comum $\delta(O_i, O_j)$ dessas duas regiões adjacentes. Esta nova segmentação:

$(\mu', K') = (\mu, K) \setminus \delta(O_i, O_j)$ é agora chamada uma subsegmentação.

Se a energia dessa nova subsegmentação for menor que a energia anterior (antes de juntarmos as duas regiões), ou seja:

$$E(\mu', K') < E(\mu, K)$$

então, é interessante a junção dessas duas regiões. Porém antes de juntarmos estas duas regiões devemos fazer o mesmo para todas as regiões vizinhas à estas duas regiões O_i e O_j e verificarmos qual é a junção que ocasionará o **maior** decréscimo de energia.

Caso não se encontre nenhuma região adjacente que ocasione nenhum decréscimo de energia, ou seja:

$$E(\mu', K') \geq E(\mu, K)$$

então, a segmentação (μ, K) é chamada de 2-normal.

Quando não for mais possível juntar nenhuma região, deve-se aumentar o valor de lambda. O incremento de lambda poderá ser linear ou exponencial.

Implementando o Modelo Simplificado Mumford-Shah

O critério de juntar duas regiões O_i e O_j está na dependência do sinal de $E(K) \setminus \delta(O_i, O_j) - E(K)$, no qual é apenas o decréscimo de energia. Assim a equação para o critério fica:

$$E(K \setminus \delta(O_i, O_j)) = \frac{|O_i| * |O_j|}{|O_i| + |O_j|} * \|u - g\|^2 - \lambda * l\delta(O_i, O_j)$$

Fórmula 15:

onde:



$|O_i|$ - Área da região O_i

$|O_j|$ - Área da região O_j

μ_i - valor de intensidade da região i

μ_j - valor de intensidade da região j

$l\partial(O_i, O_j)$ - Comprimento da fronteira entre as regiões O_i e O_j

O critério foi calculado da seguinte maneira:

$$u_i = \frac{1}{|O_i|} \int_{O_i} g(x) dx \Rightarrow \int_{O_i} g(x) dx = |O_i| * u_i$$

$$u_j = \frac{1}{|O_j|} \int_{O_j} g(x) dx \Rightarrow \int_{O_j} g(x) dx = |O_j| * u_j$$


$$u_i + u_j = \frac{1}{|O_i| + |O_j|} \int_{O_i \cup O_j} g(x) dx = \frac{1}{|O_i| + |O_j|} \left(\int_{O_i} g(x) dx + \int_{O_j} g(x) dx \right)$$

$$E(K \setminus \partial(O_i, O_j)) = \frac{|O_i| * |O_j|}{|O_i| + |O_j|} * \|u - g\|^2 - \lambda * l\partial(O_i, O_j)$$

Exemplos

Figura 3.8.

Exemplos utilizando-se passo linear



Observação


Uma vez definida as regiões ficou fácil determinar as bordas de interesse da imagem original. Onde o valor da intensidade muda de valor é uma




borda, assim pintamos esse ponto de preto, caso ele se mantenha o mesmo pintamos de branco. Assim para os exemplos anteriores temos:

Figura 3.9.

Bordas de regiões geradas pelo Mumford&Shah





Segmentação de Imagens Coloridas por Crescimento de Regiões Hierárquico

O método aqui descrito, denominado *CSC - Color Structure Code*, foi pesquisado e desenvolvido por Volker Rehrmann e Prof. Lutz Priesse do Image Recognition Lab da Universidade de Koblenz-Landau.

Um importante passo para os sistemas de análise de imagens é a identificação de regiões homogêneas na imagem. Encontra-se vários métodos de segmentação na literatura e são bem distintos. Dentre eles são os de detecção de bordas (edges detection), separação e junção (split and merge), crescimento de região (region growing) e técnicas de agrupamento (clustering). Durante três décadas se desenvolveu métodos de segmentação sempre voltados para imagens com tons de cinza. Porém as técnicas e equipamentos para a aquisição de imagens coloridas vêm se tornando mais baratos e mais comuns, a análise de imagens coloridas torna-se cada vez mais importante.

Na segmentação colorida normalmente é usado o método de agrupamento. Depois, métodos estatísticos são aplicados para buscar alguns grupos neste espaço de características. Estes agrupamentos, remapeando a imagem, formam os segmentos coloridos. A vantagem do método de agrupamento é a visão global dos dados nas formas de histograma. Porém esta visão global não reflete a informação espacial para que a imagem seja compreendida. A extensão dos agrupamentos na característica do espaço muitas vezes é ambígua e os métodos estatísticos solucionam este problema que é computacionalmente intenso. Na Figura 3.10 na página 54 pode-se visualizar o resultado da utilização do CSC em comparação com dois outros métodos de segmentação de imagens coloridas comumente utilizados.

Para a segmentação por crescimento de região utilizando CSC são usadas informações locais e globais e foram encontrados resultados de segmentação colorida muito robustos em cenas coloridas naturais.



Figura 3.10. Exemplo de três diferentes métodos de segmentação de imagens coloridas



Color Structure Code (CSC)


Split&Merge


Recursive Histogram Splitting

Estrutura de Ilha Hierárquica

O método de segmentação responde a uma hierarquia de crescimento por região e uma topologia hexagonal espacial. Ela é formada por diferentes níveis sendo que o nível 0 consiste em sete pixels vizinhos na topologia hexagonal.

Figura 3.11. A Estrutura de Ilha Hierárquica






A operação de uma topologia hexagonal tem maiores dificuldades na prática. O particionamento desta imagem na topologia hexagonal começa pelo nível 0, ele sendo composto de sete pixels e em seu laço tem seis ilhas vizinhas em exatamente um pixel. A hierarquia é continuada até os altos níveis no mesmo caminho na topologia hexagonal.

O único problema de se aproximar são as diferentes definições de vizinhança de píxeis possíveis.

Figura 3.12.

Enfoque para a criação de “ilhas” de sete píxeis



Código Estrutural de Cores

A generalização do *CSC (Color Structure Code)* opera essencialmente em quatro fases. Na repressão de nós na fase de pré-processamento e acabado para usar um filtro não linear. Em uma fase de inicialização da imagem é particionado em pequenas regiões coloridas de uma ilha de nível 0. Estas pequenas regiões de cores vão crescendo na fase de ligação em uma maneira hierárquica para completar as regiões. Como na região do laço é possível de detectar as conexões de regiões coloridas para uma cadeia de cores suaves para depois poder dividi-los. Isto é iniciado na "fase de divisão".

Fase de Pré-Processamento

Na fase de pré-processamento são usadas técnicas apropriadas como filtros lineares simples que repassam o centro do pixel para um peso médio com os pixels da vizinhança que tem desvantagem de borrar as bordas. Para proteger as bordas das borradas enquanto um filtro é usado



para adaptar-se a mudança de local na estrutura para o sinal da imagem subjacente. Ele passa por três filtros com as propriedades desejadas: o **filtro de mediana** (*median filter*), o **knn** - filtro de vizinhança de k elementos - (*k-nearest-neighbour filter*) e o **snn** - filtro de vizinhança de simétrico - (*symmetric nearest-neighbour filter*).

Fase de Inicialização

Na fase de inicialização regiões homogêneas coloridas no nível 0 das ilhas de sete pixels são detectadas e mapeadas para os elementos de nível 0 das ilhas de sete pixels são detectadas e mapeadas para os elementos códigos iniciais. Assim um elemento de código inicial consiste nos seus pixels de nível 0 das ilhas que são vizinhos e cuja distância das cores mútuas ficam abaixo a um certo limiar. Os pixels não ligados no mesmo caminho a um esquema de crescimento de região de ligação simples. Um elemento de código é uma descrição da estrutura de dados de regiões coloridas como uma ilha.

Figura 3.13.

Dois exemplos de inicialização de elementos de código




Fase de Ligação

Na fase de ligação os elementos dos códigos do nível n são ligados a elementos de código novos de nível $n + 1$ em sete ilhas sobrepõem-se parcialmente aos vizinhos na estrutura de ilhas hexagonais. Elementos de código ligam-se em representações de regiões para serem conectadas em cores similares. A conectividade dos elementos de código podem simplesmente serem determinados como uma estrutura de ilhas hexagonais: dois elementos de código são conectados em sua parte a uma comum sub-região e sua subilha.



A ligação dos elementos de código de uma ilha é similar a operação da fase de inicialização. Em vez disso para a ligação simples de pixels, regiões são ligados. Assim todas as operações de uma ilha podem ser inicializadas independentemente das outras ilhas. Os resultados das segmentações não dependem de outros para executar. Todas as pequenas regiões coloridas da fase de inicialização são crescimento concorrentes de um nível.

Figura 3.14.

Fase de Ligação de Ilhas

A sobreposição parcial as ilhas levam a conectividade eficiente checada pelo elemento dos códigos. A estrutura hexagonal de ilhas assegura que as regiões vão crescer em todas as direções em comparação para técnicas de crescimento de regiões comuns.

Fase de Divisão


Um bom algoritmo de segmentação deve usar as informações locais e as globais. Isso resolve o problema para adicionar cores similares checadas entre elementos de código conectados em todos os níveis de ligação. Se a distância da cor está acima de um certo limiar de dois códigos de elementos não serão ligados embora eles são conectados por uma cadeia de cores similares de pixels.



Se a distância entre as cores de r_1 e r_2 é muito grande, ele não precisa ser ligado, embora todas as suas sub-regiões no nível $n - 1$ são localmente homogêneas.

Figura 3.15.

Divisão de Regiões




Similaridade de Cores no CSC

A medida da similaridade de cores publicada são medidas calculando a proporção da distância de cores média e suas variâncias. As medidas são mais orientadas a propriedades estatísticas que sensações humanas a cores. Suas medidas não correspondem ao julgamento humano, ele desenvolve um novo predicado de cor no espaço de cores HSV. No modelo de cores HSV a cor é descrita por três atributos o tom, a saturação e o valor.

Figura 3.16.

Representação do Espaço de Similaridade de Cores: A representação gráfica de tabelas de limiares (tom, saturação e valor sequencialmente)

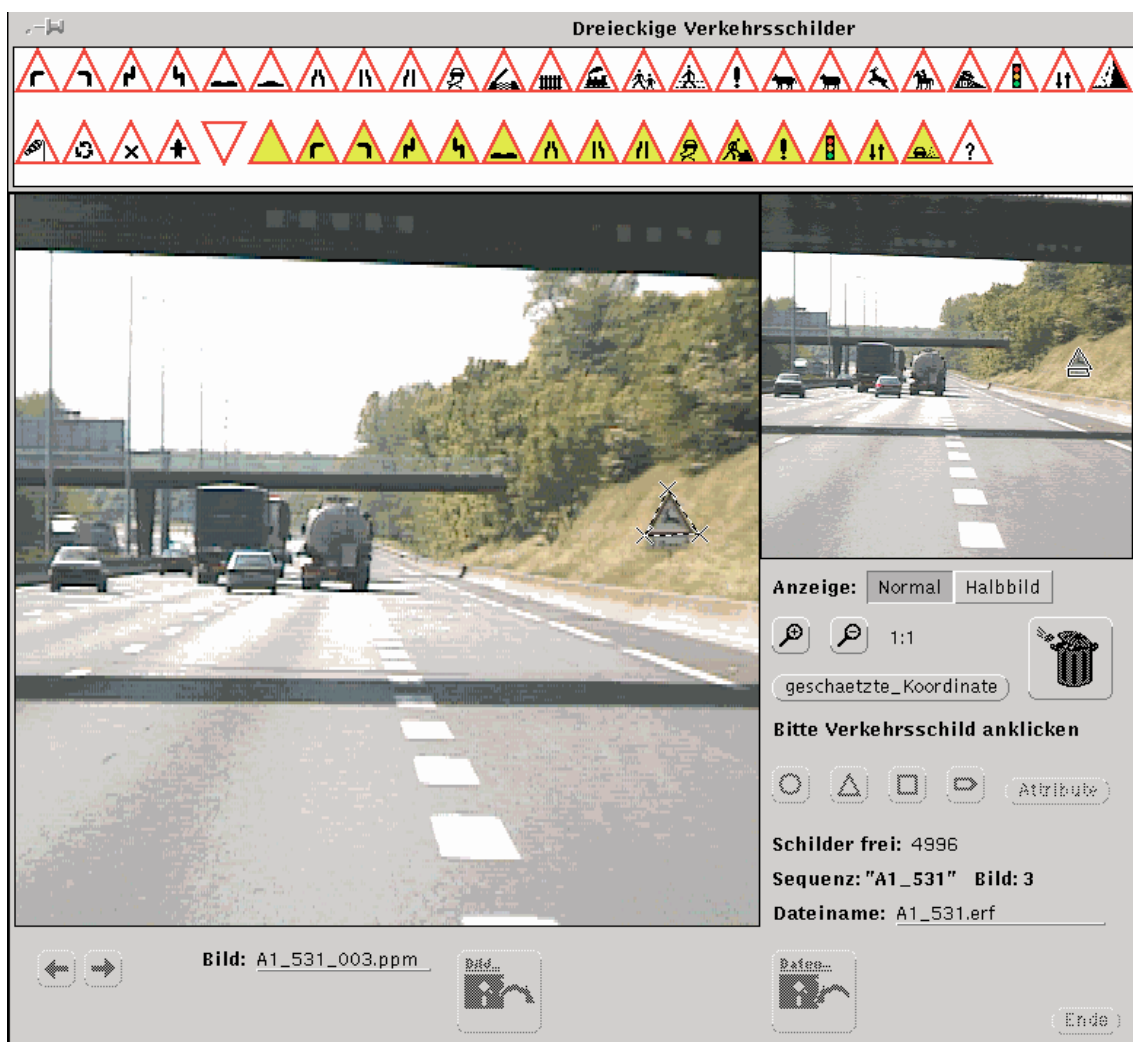


Resultados do uso de CSC

Na aplicação feita e publicada por Volker Rehrmann e Lutz Priesse teve sucesso no seu objetivo; o sistema reconhece os sinais de trânsito e é baseado em CSC e foi testado em um protótipo de piloto automático implantado pela Daimler-Benz. O sistema opera em tempo real e tem um excelente reconhecimento.



Figura 3.17. Exemplo de Aplicação em uma cena rodoviária alemã





Ferramentas de Software para a Segmentação por Crescimento de Regiões

Podemos considerar separadamente as implementações do crescimento de regiões simples, sem quaisquer critérios a não ser os valores de pixel (que não foi discutida neste capítulo por ser de pouca utilidade), as implementações do funcional de Mumford e Shah e as implementações do Watershed.

Crescimento de Regiões Simples do Khoros 1.0.5

Khoros [2.6][2.7] (Veja também “Uma Ferramenta de Programação Visual: Khoros” na página 167) oferece uma rotina simples de segmentação por crescimento de regiões. Abaixo alguns resultados.

Figura 3.18.

Imagem original e resultado do processamento através do Khoros

Crescimento de Regiões utilizando o Funcional de Mumford e Shah

Podemos diferenciar entre implementações com passo exponencial de λ e com passo linear de λ .

A melhor implementação de passo exponencial sem dúvida é a rotina `mumshah` do pacote `MegaWave`, desenvolvido pelo CEREMADE em Grenoble [2.5]. `MegaWave` é um pacote relativamente simples de rotinas de análise de sinais primordialmente voltado à análise de texturas, implementado nos primórdios do desenvolvimento das ondeletas (wavelets), de onde vem o nome. Curiosamente, este pacote implementa também algumas rotinas de análise de sinais não voltadas à análise de texturas, dentre estas uma excelente implementação do funcional de Mumford e Shah com passo exponencial.

Figura 3.19.

Alguns exemplos. À esquerda as imagens originais. À direita de cada segmentação o valor final de x de λ^x



Implementações de passo linear existem mais. Uma versão Khoros-compatível muito bem documentada foi desenvolvida início dos anos 90 em uma tese de mestrado do Departamento de Matemática da Universidade de Kaiserslautern [2.2]. Há também uma versão para MS-Windows, baseada nesta documentação, desenvolvida por Paulo Pizarro do Departamento de Engenharia Elétrica da UFSC durante o correr da disciplina de Visão Computacional do Curso de Pós-Graduação em Ciências da Computação da UFSC para a qual o presente livro é material de ensino na UFSC.

Figura 3.20. Alguns exemplos. À esquerda as imagens originais. À direita de cada segmentação o valor final de λ

Crescimento de Regiões com Divisor de Águas

Sem dúvida uma das melhores e mais bem testadas implementações do region-growing com watershed é denominada `viterRegGrow` e foi implementada por Gangolf Mittelhäusser no Departamento de Informática da Universidade de Kaiserslautern [2.3][2.4]. Esta implementação foi utilizada extensivamente para as mais variadas finalidades, tanto pela própria Universidade de Kaiserslautern, como pelo Instituto Max-Planck de Psicologia Cognitiva em Leipzig, por nós e muitos outros. Atualmente existe uma versão deste algoritmo disponível no pacote BRIAN (BRain Image ANalysis), que vem sendo desenvolvido pelo Instituto Max Planck. O `viterRegGrow` possui a característica de realizar segmentação de imagens 3D, caso se forneça um arquivo representando um volume de dados, como uma tomografia computadorizada, por exemplo. Para que `viterRegGrow` opere em 3D, é necessário que as imagens sejam fornecidas como série no formato VISTA [2.8][2.9].

Figura 3.21. Imagens anteriores agora segmentadas através de Watershed

Um aspecto importante desta implementação é o de que ela não calcula os gradientes necessários para a determinação dos divisores de águas. Este cálculo deve ser efetuado em separado, de preferência através da utilização do algoritmo de Canny. A imagem de gradientes gerada é

Referências



também fornecida ao algoritmo. Uma excelente implementação do Canny pode ser encontrada no pacote VISTA [2.8][2.9]. Versões anteriores do BRIAN também continham esta implementação do Canny.

Figura 3.22.

Canny com valores variados de σ aplicados às imagens originais acima. O resultado mais à esquerda é sempre o que gerou a segmentação da figura anterior.

Para o pré-processamento de volumes de imagens, existe uma versão tridimensional do Canny denominada Canny3D disponível no pacote BRIAN.

Referências

- [2 . 1] **Mumford D., Shah J.;** *Optimal Approximations by Piecewise Smooth Functions and Associated Variational Problems*, Comm. Pure Appl. Math., 1989.
- [2 . 2] **Klausmann, Peter;** *Variational Methods in Image Segmentation*. Diplomarbeit, Fachbereich Mathematik, Universität Kaiserslautern, Kaiserslautern, Mai 1995.
- [2 . 3] **Mittelheuser, Gangolf und Kruggel, Frithjof;** *Fast Segmentation of Magnetic Resonance Tomograms*, Interner Bericht, AG Zimmermann, FB Informatik, Universität Kaiserslautern, Kaiserslautern, November, 1994.
- [2 . 4] **Mittelhaeusser G., Kruggel F.;** *Fast Segmentation of Brain Magnetic Resonance Tomograms*. CVRMed'95: First International Conference on Computer Vision, Virtual Reality and Robotics in Medicine, Nizza, 1995.
- [2 . 5] **Froment, Jacques;** *MEGAWAVE - Un environnement de développement orienté Traitement d'Images sous Unix et Ms/Dos*, CEREMADE, Université de Paris IX, 4.Edition, Paris, France, 1990.
- [2 . 6] **The Khoros Group;** *Khoros User's Manual, Release 1.0.5*, Vols. I - III, Department of Electrical Engineering & Computer Engineering, University of New Mexico, Albuquerque, USA, 1993.



- [2 . 7] www.khoral.com/
- [2 . 8] **Pope, Arthur;** *VISTA Software Documentation. Version 2.1.* Laboratory of Computational Intelligence, University of British Columbia, Vancouver, Canada, Juni, 1994.
- [2 . 9] **Pope, Arthur R., Lowe, David G.;** *VISTA: A Software Environment for Computer Vision Research.* Internal Report, Department of Computer Science, University of British Columbia, Canada, 1994